Imię i Nazwisko: Krzysztof Dąbrowski	**Kierunek:** IAD	**PUNKTACJA**
Prowadzący: AK		/ 8

Raport z Kamienia Milowego 1: Eksploracja i przygotowanie danych

1 Eksploracyjna analiza danych

Zbiór treningowy ma 6400 obserwacji i 23 cechy numeryczne. Część z nich to zmienne kategoryczne zapisane liczbami: `SEX`, `EDUCATION`, `MARRIAGE` i porządkowe: `PAY_*`. Klasy w targecie są niezbalansowane, około 78% obserwacji jest klasy 0 i 22% jest klasy 1.

1.1 Statystyki opisowe i rozkłady zmiennych

Cechy kwoty `LIMIT_BAL`, `BILL_AMT*`, `PAY_AMT*` mają średnią wyraźnie większą od mediany i długi prawy ogon, co wskazuje na ich prawoskośność. Zmienne `PAY_*` skupiają się w wartościach -2, -1 i 0 (w każdym miesiącu 77–91% klientów ma status ≤ 0). Wyższa wartość oznacza gorszy status spłaty, więc traktuję `PAY_*` jako zmienne porządkowe.

1.2 Analiza wartości brakujących

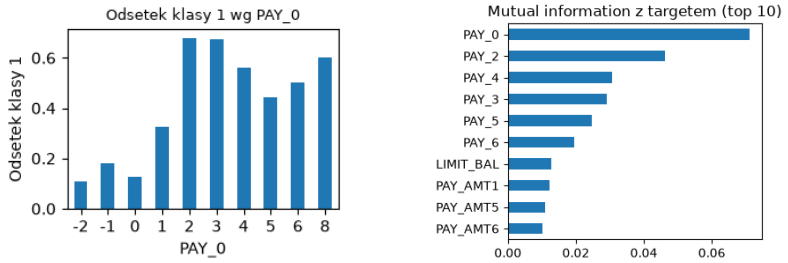
Braki występują tylko w `PAY_5`, `BILL_AMT6` i `PAY_AMT4`, w każdej jest to prawie 10% obserwacji (również w `X_test`). Zwykle dotyczą pojedynczych kolumn (tylko 174 wiersze mają ponad 1 brak), a odsetki klasy 1 wśród wierszy z brakiem i bez są zbliżone, więc braki wyglądają na losowe.

1.3 Wykrywanie wartości odstających

Outliery IQR dotyczą głównie kwot (blisko 10%), powodem jest prawoskośność, nie błędy. Ujemne `BILL_AMT` mogą oznaczać nadpłatę, a ujemne `PAY_AMT` trudno jednoznacznie zinterpretować (np. zwrot środków lub korekta); jest ich dużo, więc nie traktuję ich jako błędów. Ujemny `LIMIT_BAL` i wartość -3 w `PAY_3` (po jednej obserwacji) to prawdopodobnie błędy w danych. Kategorie "inne" w `EDUCATION` i `MARRIAGE` są rzadkie i rozbite na kilka kodów.

1.4 Analiza relacji i istotności zmiennych

Widać silnie skorelowane grupy cech: `BILL_AMT1-6` oraz `PAY_0-6`. Korelacja Pearsona mierzy zależność liniową, dlatego policzyłem też *mutual information*, które potrafi wychwycić zależności nieliniowe. Potwierdza ono wnioski z korelacji: najważniejsze są statusy spłat `PAY_*` oraz `LIMIT_BAL`, a kwoty rachunków `BILL_AMT*` niosą niewiele informacji o targecie. Dla `PAY_0` ≤ 0 odsetek klasy 1 wynosi poniżej 0.2, dla `PAY_0` $= 1$ około 0.32, a dla 2+ ok. 0.4-0.7 (Rys. 1). Z analizy wynika również że im wyższy limit kredytowy, tym mniejsze ryzyko klasy 1.



Rys. 1. Odsetek klasy 1 w zależności od `PAY_0` (lewo) oraz 10 cech o najwyższym *mutual information* z targetem (prawo).

Na etapie KM1 wykorzystuję wszystkie cechy, bez usuwania outlierów i bez imputacji: drzewo decyzyjne samo wybiera cechy i jest odporne na wartości odstające, a `DecisionTreeClassifier` w sklearn obsługuje braki danych.

2 Metryka ewaluacji i podział danych

2.1 Wybór metryki

Model końcowo ma zwracać prawdopodobieństwa przynależności do klasy 1, dlatego wybrałem metrykę, która ocenia prawdopodobieństwa i nie zależy od progu odcięcia. Główną metryką będzie **ROC AUC**, ponieważ ocenia, jak dobrze model porządkuje klientów według ryzyka, nie zależy od wyboru progu (w przeciwieństwie do precision, recall i F1), a model losowy ma wartość 0.5, więc wynik łatwo zinterpretować. Na metrykę pomocniczą wybrałem **Average Precision (AP)**, która skupia się na rzadszej klasie 1 i przy niezbalansowanych klasach jest surowsza niż ROC AUC. Accuracy nie jest odpowiednia, ponieważ model, który zawsze przewiduje 0, miałby accuracy około 0.78, a nie wykrywa żadnego klienta w zwłoce.

2.2 Strategia podziału danych

Podzieliłem `X_train` w sposób stratyfikowany 80/20. Na 80% dobieram hiperparametry za pomocą 5-krotnej stratyfikowanej walidacji krzyżowej, a 20% to zbiór walidacyjny, użyty raz, do końcowej oceny wybranego modelu.

3 Optymalizacja hiperparametrów drzewa decyzyjnego

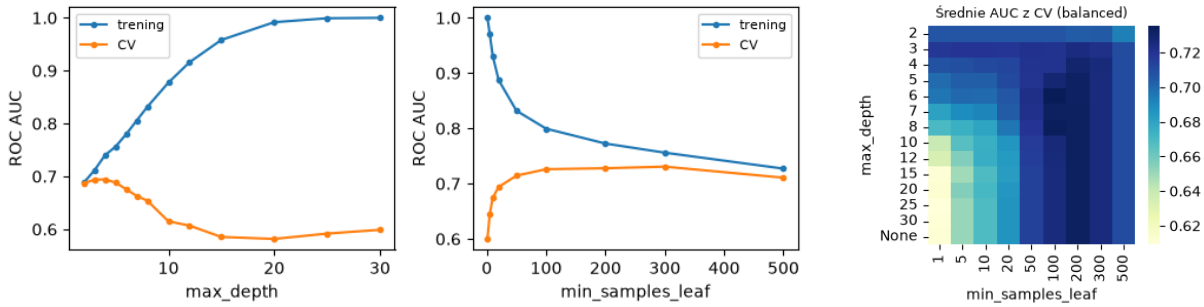
3.1 Wybór hiperparametrów i przestrzeń poszukiwań

Drzewo z domyślnymi parametrami (głębokość 34, 709 liści) jest przeuczone; na treningu osiąga AUC = 1.0, a w walidacji krzyżowej tylko 0.60. Dlatego wybrałem hiperparametry, które kontrolują jego złożoność:

- `max_depth`, z zakresem: 2-8, 10, 12, 15, 20, 25, 30, `None` - od płytkiego drzewa do braku limitu,
- `min_samples_leaf`, z zakresem: 1, 5, 10, 20, 50, 100, 200, 300, 500 - duże liście dają stabilniejsze prawdopodobieństwa,
- `class_weight`, z wartościami `None` albo `balanced` - aby sprawdzić czy przy niezbalansowanych klasach pomaga większa waga klasy 1.

Łącznie $14 \times 9 \times 2 = 252$ kombinacje, przeszukane za pomocą `GridSearchCV` z 5-krotną stratyfikowaną CV.

3.2 Wpływ hiperparametrów na metrykę



Rys. 2. Krzywe walidacyjne dla `max_depth` i `min_samples_leaf` (lewo) oraz średnie AUC z CV w siatce dla `class_weight` = `balanced` (prawo).

Dla `max_depth` AUC na treningu rośnie aż do 1, a AUC w CV osiąga maksimum około 0.69 przy głębokości 4, a potem spada. Dla `min_samples_leaf` im większe liście, tym wyższe AUC w CV (maksimum około 0.73 przy 300). W siatce najważniejsze jest `min_samples_leaf`: przy małych liściach głębokie drzewa mocno się przeuczają, a przy liściach 100-300 wynik jest stabilny niezależnie od głębokości. `class_weight` ma niewielki wpływ (najlepsze wyniki to 0.735 dla `balanced`, 0.733 dla `None`). Optimum leży wewnątrz siatki, więc zakresy były dobrane poprawnie, a najlepsze kombinacje różnią się w AUC o ułamki tysięcznych, mniej niż odchylenie standardowe między foldami - około 0.02.

3.3 Wybrany model i ocena na zbiorze walidacyjnym

Wybrany model (wskazany przez GridSearch): `max_depth` = 6, `min_samples_leaf` = 100, `class_weight` = `balanced`. Ma najwyższe AUC w CV, a przy tym jest mały (20 liści).

Na zbiorze walidacyjnym osiąga AUC 0.754, trochę więcej niż w CV (0.735), ale różnica mieści się w rozrzucie między foldami, więc model dobrze uogólnia. AUC na treningu wynosi około 0.77, więc model nie jest przeuczony. AP to w przybliżeniu 0.5, ponad dwukrotnie więcej niż klasyfikator losowy (0.22). Drzewo opiera się przede wszystkim na `PAY_0` (ważność ponad 0.6) i `PAY_3` (około 0.17), co jest zgodne z EDA.

	pełne	wybrane
AUC trening	1.000	0.771
AUC CV	0.600	0.735
AUC walidacja	0.616	0.754
AP walidacja	0.283	0.495

Tab. 1. Pełne drzewo vs wybrany model.

4 Podsumowanie i wnioski

Najsilniej z targetem związane są statusy spłat `PAY_*`, szczególnie `PAY_0`. Pełne drzewo jest silnie przeuczone, a strojenie poprawiło AUC na zbiorze walidacyjnym z 0.62 do 0.75, a AP z 0.28 do 0.50. Kluczowe okazało się ograniczenie złożoności drzewa przez `min_samples_leaf`, natomiast `class_weight` praktycznie nie zmienił wyniku, bo ROC AUC ocenia tylko kolejność klientów, a niezbalansowanie klas mu nie przeszkadza.